



ORACLE AI VECTOR SEARCH)

DETECTAREA DUPLICATELOR SAU A
SIMILARITATII ÎNTRE DOCUMENTE


ION MELANIA VICTORITA
OLTEAN DELIA ALEXANDRA
ONORIU ELISABETA MARIA

INTRODUCERE & SCOP

- Proiectul implementează identificarea documentelor similare sau duplicate folosind Vector Search
- Documentele (ex: fișiere DOCX) sunt transformate în vectori (embeddings)
- Similaritatea se calculează folosind distanța cosine
- **Scop:**
 - Detectarea duplicatelor
 - Identificarea documentelor „aproape identice”
 - Clasificarea gradului de similaritate

Key takeaway:

Nu comparăm textul direct, ci sensul semantic al documentelor




ARHITECTURĂ & FLUX




1. Stocare documente

- Fișierele sunt salvate în DB (BLOB + CLOB + vector)
- Tabel: documente_word



2. Preprocesare

- Extrage text din DOCX (Oracle Text)
- Textul este salvat în câmp CLOB



3. Generare embeddings


- Model ONNX (ex: MiniLM)
- Transformă textul în vector numeric



4. Comparare vectorială

- Se calculează:
 - VECTOR_DISTANCE(..., COSINE)
- Se obține scorul de similaritate

DETECTAREA SIMILARITĂȚII & REZULTATE



Exemple:

- 2. Penguins_Main vs Penguins_Copy → identice
- 2. Documente diferite → scor mare

Use cases:

- Detectare plagiat
- Eliminare duplicate
- Recomandare documente similare

